

Designing Great Data Products

Jeremy Howard, Margit Zwemer y Mike Loukides.

La Idea Principal: Dejar de Predecir y Empezar a Actuar

El artículo argumenta que la comunidad de ciencia de datos está **obsesionada con la predicción**, pero la predicción por sí sola no sirve de mucho. Es como tener un meteorólogo que predice con un 99% de exactitud que va a llover, pero nunca te dice que lleves un paraguas.

El verdadero valor no está en predecir el futuro, sino en **tomar acciones para cambiarlo a nuestro favor**. Un producto de datos verdaderamente genial no solo te da una predicción, sino que te recomienda o ejecuta la **mejor acción posible** para lograr un objetivo.

Para lograr esto, los autores proponen el “**Drivetrain Approach**” (**Enfoque de Tren de Transmisión**), un método sistemático inspirado en los coches autónomos, que no solo predicen el camino, sino que giran el volante y pisán el acelerador para llegar a su destino.

Los 4 Pasos del Drivetrain Approach

Este es el corazón del método. En lugar de empezar por los datos o los algoritmos, se empieza por el final: el objetivo.



Figura 1. Los cuatro pasos del Drivetrain Approach: Objetivo Definido, Palancas (Levers), Datos y Modelos.

1. Paso 1: Definir un Objetivo Claro (Defined Objective)

- **La Pregunta:** ¿Qué resultado estoy tratando de lograr?

- **Explicación:** Este es el paso más importante. Debes empezar con un objetivo de negocio, claro y medible. El error común es definir el objetivo en términos del modelo (ej: “predicir qué clientes se darán de baja”). Un buen objetivo es definirlo en términos del negocio (ej: “maximizar el valor de vida del cliente”).
- **Ejemplo de Google:** El objetivo no era “encontrar páginas relevantes”, sino “mostrar al usuario el resultado más relevante en la primera posición”.

2. Paso 2: Identificar las Palancas (Levers)

- **La Pregunta:** *¿Qué entradas podemos controlar?*
- **Explicación:** Una vez que tienes el objetivo, debes identificar qué “botones” o “palancas” puedes accionar para influir en ese objetivo.
- **Ejemplo de una aseguradora:** Las palancas son el precio de la póliza, el gasto en marketing, los tipos de accidentes que se cubren, etc.

3. Paso 3: Recopilar los Datos (Data)

- **La Pregunta:** *¿Qué datos necesitamos recolectar?*
- **Explicación:** Ahora necesitas datos que conecten tus palancas con tu objetivo. A menudo, los datos que ya tienes no son suficientes. Puede que necesites realizar experimentos para generar nuevos datos.
- **Ejemplo de Google:** Se dieron cuenta de que los enlaces entre páginas eran un dato crucial para entender la relevancia (si muchas páginas importantes enlazan a otra, esta debe ser importante).

4. Paso 4: Construir los Modelos (Models)

- **La Pregunta:** *¿Cómo influyen las palancas en el objetivo?*
 - **Explicación: Solo ahora,** al final del proceso, construyes los modelos predictivos. Estos modelos no son el producto final; son solo los engranajes del sistema. Su función es modelar la relación entre las palancas (y otras variables no controlables) y el objetivo.
-

La Línea de Ensamblaje de Modelos: El Caso de Estudio de Seguros (ODG)

Para explicar el Paso 4 en detalle, los autores usan un caso de estudio real de una empresa que optimizó los precios de las pólizas de seguros. A este sistema lo llaman la “**Línea de Ensamblaje de Modelos**” (**Model Assembly Line**).

El objetivo era **maximizar el beneficio a largo plazo por cada cliente**. Para lograrlo, no bastaba con predecir el riesgo de accidente de una persona. Construyeron una “línea de ensamblaje” con tres estaciones:

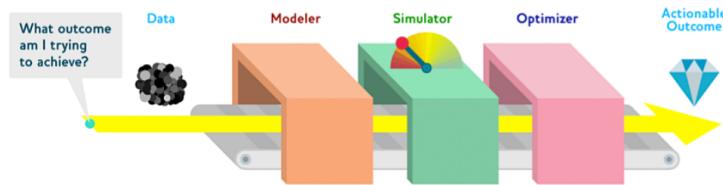


Figura 2. Drivetrain Paso 4: La Línea de Ensamblaje de Modelos (Model Assembly Line). El diagrama muestra cómo los datos brutos pasan a través de un Modelador, un Simulador y un Optimizador para producir un resultado accionable.

1. El Modelador (Modeler):

- **Función:** Crea los modelos predictivos individuales.
- **Ejemplos de modelos:**
 - Un modelo de **elasticidad de precio** (¿cuál es la probabilidad de que un cliente acepte un precio determinado?).
 - Un modelo de **rentabilidad esperada** (¿cuánto beneficio se espera de un cliente a ese precio, considerando el riesgo?).
 - Un modelo de **retención de clientes** (¿cuál es la probabilidad de que el cliente renueve su póliza el próximo año?).

2. El Simulador (Simulator):

- **Función:** Es el motor de “What-if” (¿Qué pasaría si...?). Usa los modelos del *Modeler* para simular miles de escenarios posibles.

- **Preguntas que responde:** “¿Qué pasaría con nuestro beneficio si bajamos el precio un 10%?” o “¿Qué impacto tendría si un nuevo competidor entra al mercado y no hacemos nada?”.

3. El Optimizador (Optimizer):

- **Función:** Es el “cerebro” del sistema. Analiza todos los resultados del *Simulador* y encuentra la **mejor combinación de palancas** para maximizar el objetivo.
 - **La Salida Final:** No es una predicción, es una **acción**: “Para este cliente específico, el precio óptimo a cobrar es de \$957 al año”.
-

Aplicando el Enfoque a Sistemas de Recomendación

Los autores critican los motores de recomendación tradicionales (como el de Amazon en esa época) por no seguir este enfoque.

- **Problema:** Se centran en un objetivo simple: “predecir qué le gustará al usuario”. El resultado es que te recomiendan cosas obvias que ya conoces (ej: si buscas un libro de Terry Pratchett, te recomienda más libros de Terry Pratchett). No aportan valor real y te encierran en una “burbuja de filtros”.
- **Solución con Drivetrain:**
 - **Nuevo Objetivo:** “Impulsar ventas adicionales sorprendiendo al cliente con libros que **no habría comprado sin la recomendación**”.
 - **Nuevos Modelos:** Construir un modelo que calcule la “utilidad” de una recomendación (la probabilidad de compra *con* la recomendación menos la probabilidad de compra *sin* ella).
 - **Optimización:** Mostrar las recomendaciones con la mayor utilidad, no las más obvias.

Optimización del Valor de Vida del Cliente (Ejemplo de Marketing)

El “valor de vida del cliente” se refiere al beneficio neto total que una empresa espera obtener de un cliente durante toda su relación comercial.

El enfoque se puede extender a toda la estrategia de marketing.

- **Objetivo:** Optimizar el valor de vida de cada cliente.
- **Palancas:** Recomendaciones, descuentos personalizados, promociones por email, etc.
- **Datos:** Se pueden recolectar de formas creativas. El ejemplo de Zafu, una tienda de jeans online, es genial: en lugar de mostrar el catálogo, primero le hacen preguntas a la clienta sobre su tipo de cuerpo y sus preferencias. Convierten la experiencia de compra en un mecanismo de recolección de datos.

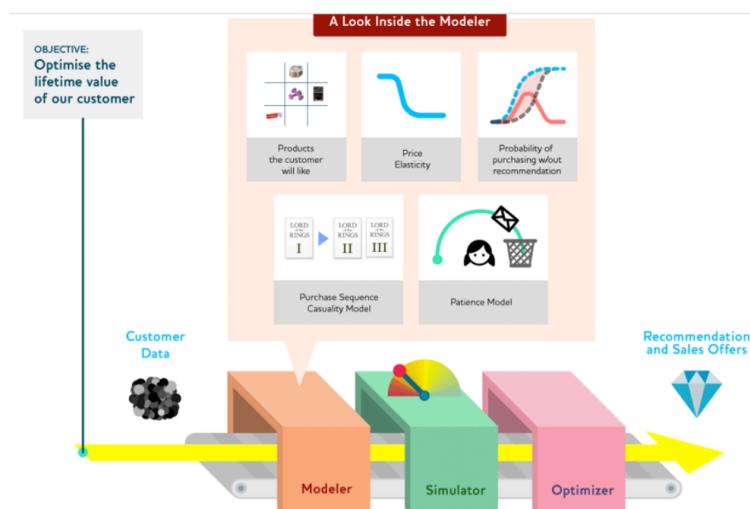


Figura 3. Un vistazo dentro del Modelador. El diagrama muestra varios sub-modelos que componen el Modelador, como un modelo de ‘productos que le gustarán al cliente’, ‘elasticidad de precio’, ‘probabilidad de compra sin recomendación’, ‘modelo de causalidad de secuencia de compra’ y ‘modelo de paciencia’.

Lecciones del Mundo Físico y el Coche Autónomo

- **Ingeniería de Sistemas:** Los autores señalan que los ingenieros industriales y de sistemas han pensado de esta manera durante décadas. No construyen un motor y luego buscan un coche donde ponerlo; empiezan con el objetivo (“un coche que transporte personas”) y diseñan todos los componentes para que trabajen juntos.
- **El Coche Autónomo (La analogía completa):**
 - **Objetivo:** Construir un coche que se conduzca solo de forma segura.
 - **Palancas:** Volante, acelerador, frenos.
 - **Datos:** Sensores y cámaras que leen el entorno.
 - **Modelos:** Modelos de física y reconocimiento de patrones.
 - **El Salto Clave:** El coche no solo **predice** que va a haber un accidente. El **Optimizador** simula las posibles acciones (frenar, girar) y elige la **mejor acción para evitar el accidente**. La predicción está al servicio de la optimización.

Conclusión: El Futuro de los Productos de Datos

El mensaje final es un llamado a la acción para la comunidad de ciencia de datos:

¿Queremos productos que entreguen más **datos** (predicciones), o queremos productos que entreguen **resultados basados en datos** (acciones)?

El futuro no está en construir modelos predictivos más precisos, sino en integrarlos en sistemas que **optimizan resultados y automatizan decisiones**, transformando industrias en el proceso.